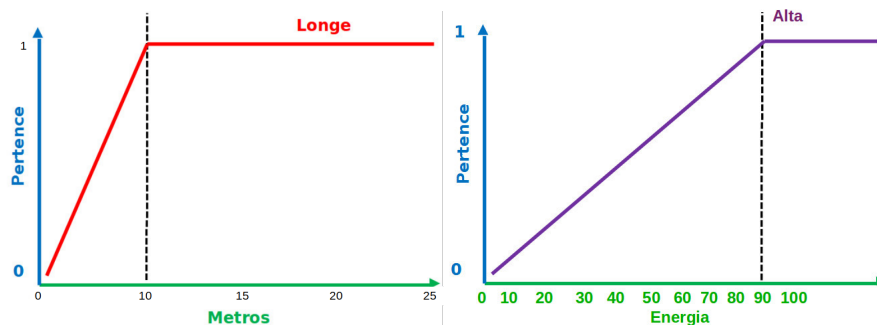


Nome:

1. (2,0 pt) Usando apenas as etapas de fuzzyfication e inference, determine, para o personagem de um jogo, a sua próxima ação: fugir, combater, esconder-se ou descansar. Para isso, considere a base de regras e as funções de pertinência a seguir. Considere também que o inimigo está a 8 m de distância e que o personagem tem 55% da sua energia. Mostre como você encontrou o resultado, exibindo os cálculos, e detalhando as etapas de fuzzyfication e inference usadas para decidir a ação do personagem. Use no máximo 2 casas decimais.

- R1: SE o inimigo estiver longe E a energia estiver baixa ENTÃO descansar
- R2: SE o inimigo estiver perto E a energia estiver baixa ENTÃO esconder-se
- R3: SE o inimigo estiver perto E a energia estiver alta ENTÃO combater
- R4: SE o inimigo estiver longe E a energia estiver alta ENTÃO fugir



$$\Gamma(u; \alpha, \beta) = \begin{cases} 0 & \text{se } u < \alpha \\ (u - \alpha) / (\beta - \alpha) & \text{se } \alpha \leq u \leq \beta \\ 1 & \text{se } u > \beta \end{cases}$$

2. (1,0 pt) Analise as afirmativas abaixo sobre Lógica Fuzzy e assinale V para afirmativa verdadeira e F para falsa.
- a) () Na etapa de fuzzyfication, usamos o método do centróide para definir os graus de pertinência a conjuntos difusos.
 - b) () A lógica fuzzy é uma extensão da lógica booleana.
 - c) () Na lógica fuzzy, o valor zero corresponde ao Falso, e os valores do intervalo contínuo (0;1] a graus de Verdade.
 - d) () No processo de inferência, o consequente da regra ativada terá o mesmo grau de verdade atribuído a sua premissa.
 - e) () É na etapa de defuzzyfication que a força de ativação das regras são definidas.

3. **(1,0 pt)** Diferencie e descreva os paradigmas de aprendizado vistos em aula, quando estudamos aprendizagem de máquina. Apresente diferenças, bem como tarefas e técnicas associadas a esses paradigmas.
4. **(1,0 pt)** Diferencie algoritmos de agrupamento particionais de aglomerativos. Como funcionam ? Vantagens e Desvantagens ?
5. **(2,0 pts)** Os dados abaixo precisam ser classificados, simule a execução do algoritmo $k-NN$, usando, para isso, a distância de Manhattan $d(x_i, x_j) = \sum_{l=1}^d |x_i^l - x_j^l|$. Mostre os cálculos realizados (use apenas uma casa decimal). Ao final de sua simulação, indique as classes para a amostra $[7, 1, 8]$, quando (a) $k = 1$; e (b) $k = 3$.

N.	Atributo1	Atributo2	Atributo3	Classe
1	2	3	5	C1
2	1	2	6	C1
3	0	1	1	C3
4	5	0	9	C2
5	1	0	1	C3
6	1	1	1	C3

6. **(2,0 pts)** Como funciona uma rede neural do tipo Perceptron ? O que acontece na etapa de aprendizagem ? O que acontece na etapa de generalização ? Em quantas classes um neurônio dessa rede consegue classificar os dados ? Quanto aos dados usados, como eles devem ser organizados para a rede aprender ? O que o algoritmo de treinamento faz ? Onde o modelo induzido fica armazenado nessa rede ? A quantidade de camadas é relevante para a aprendizagem? Por que ? (Detalhe e justifique sua resposta)
7. **(1,0 pt)** Sabendo que a tarefa é de classificação de dados e que você dispõe de um conjunto de 2000 amostras, onde cada amostra é descrita por 31 atributos e 31º atributo é a classe que pode ser A, B e C; analise as afirmações abaixo e assinale V para afirmação verdadeira e F para falsa para rede Multi-Layer Perceptron (MLP). Justifique as afirmativas falsas.
 - a) () Para resolver esse problema por uma rede neural MLP, poderíamos usar como topologia inicial $2000 \times 77 \times 3$.
 - b) () Esse rede é capaz de induzir o modelo a partir de qualquer tipo de dado, inclusive não numéricos.
 - c) () Uma época corresponde a um ciclo de aprendizagem da rede; no qual todos os dados do conjunto de treino são passados pela rede.
 - d) () A camada de entrada da rede MLP terá 30 neurônios e a de saída 1 neurônio, visto que cada amostra possui 31 atributos.
 - e) () O *underfitting* acontece quando a rede contém neurônios insuficientes para definir o modelo.